Agrupamento de Dados com BSAS, K-Means, Janelas de Parzen e KNN

Caique F. Pereira de Moura

14 de maio de 2026

Resumo

Este relatório apresenta três propostas de agrupamento aplicadas aos conjuntos Iris e Wine. A primeira combina o método BSAS com K-Means: o BSAS é utilizado para estimar o número de agrupamentos por meio da análise da curva $k(\tau)$, enquanto o K-Means realiza o particionamento final. A segunda proposta usa Janelas de Parzen para estimar a densidade dos dados e formar grupos a partir de modos de densidade. A terceira proposta usa KNN por meio de um grafo de vizinhos compartilhados. Os resultados são avaliados de forma qualitativa por visualizações em PCA 2D e comparação com as classes esperadas, com métricas externas e internas usadas apenas como apoio.

1 Introdução

O objetivo da atividade é implementar e comparar procedimentos de agrupamento não supervisionado em dois conjuntos clássicos: Iris Dataset e Wine Dataset. Embora ambos possuam rótulos conhecidos, esses rótulos não são usados no treinamento dos métodos. Eles servem apenas para avaliação qualitativa posterior, permitindo comparar os agrupamentos encontrados com as classes esperadas.

Foram implementadas três abordagens. Na primeira, o BSAS (*Basic Sequential Algorithmic Scheme*) estima o número de grupos presentes nos dados. Em seguida, esse número é passado ao K-Means, que executa o particionamento efetivo. Na segunda abordagem, Janelas de Parzen são usadas para estimar uma função de densidade, e os grupos são definidos a partir de regiões que convergem para o mesmo modo dessa densidade. Na terceira abordagem, um grafo KNN é construído usando vizinhos compartilhados, e os grupos são obtidos como componentes conexas desse grafo.

2 Pré-processamento

Antes da aplicação dos métodos, os dados foram padronizados com `StandardScaler`. Assim, cada atributo passa a ter média aproximadamente zero e desvio-padrão aproximadamente igual a um. Esse pré-processamento é necessário porque todos os métodos implementados dependem de distâncias: BSAS, K-Means, Janelas de Parzen e KNN.

Sem padronização, atributos com maior escala numérica poderiam dominar o cálculo das distâncias. Isso seria especialmente problemático no Wine Dataset, pois seus

atributos possuem unidades e amplitudes muito diferentes. Dessa forma, a padronização torna a contribuição dos atributos mais equilibrada e evita que o resultado do agrupamento seja determinado artificialmente por uma diferença de escala.

Para visualização, também foi utilizada PCA com duas componentes principais. A PCA não foi usada como entrada principal dos algoritmos de agrupamento; ela foi empregada apenas para projetar os dados em duas dimensões e permitir uma análise visual dos grupos encontrados.

3 Metodologia

3.1 BSAS para estimar o número de grupos

O BSAS é um método sequencial. A cada novo ponto, calcula-se a distância entre esse ponto e os representantes dos grupos já existentes. Se a menor distância for menor ou igual a um limiar τ, o ponto é inserido no grupo mais próximo. Caso contrário, um novo grupo é criado. Assim, τ controla diretamente o número de grupos obtidos.

Valores pequenos de τ tendem a gerar muitos grupos, pois poucos pontos são considerados suficientemente próximos dos grupos existentes. Valores grandes de τ tendem a gerar poucos grupos, pois muitos pontos passam a ser aceitos em grupos já existentes. Esse comportamento é estudado pela curva $k(\tau)$, em que k representa o número de grupos retornado pelo BSAS para cada valor de τ.

Como o BSAS é sensível à ordem de apresentação dos dados, cada valor de τ foi avaliado várias vezes com embaralhamentos diferentes. Em seguida, foi usada a mediana do número de grupos obtidos. Essa estratégia reduz o efeito de uma ordem específica dos dados e torna a estimativa de k mais estável.

A escolha de k foi feita procurando regiões de estabilidade na curva $k(\tau)$. Numericamente, foi calculada uma aproximação da derivada:

$$\frac{dk}{d\tau} \approx \nabla k(\tau). \tag{1}$$

Regiões em que $|dk/d\tau|$ é pequeno indicam que mudanças em τ alteram pouco o número de grupos. Essas regiões foram interpretadas como plateaus de estabilidade. Por outro lado, regiões com derivada alta indicam transições bruscas, nas quais pequenas variações no limiar mudam bastante o agrupamento.

3.2 K-Means como particionador final

Após estimar o número de grupos com o BSAS, o K-Means foi executado com `n_clusters = k`. Essa combinação separa dois papéis: o BSAS é usado como estimador do hiperparâmetro k, e o K-Means é responsável pelo particionamento final.

Essa proposta é interessante porque o K-Means normalmente exige que o usuário defina previamente o número de grupos. O BSAS fornece uma forma automatizada e interpretável de sugerir esse valor a partir da própria estrutura dos dados.

3.3 Agrupamento por Janelas de Parzen

Na segunda proposta, foi estimada uma densidade por Janelas de Parzen com kernel Gaussiano. Para um ponto x, a densidade estimada pode ser escrita como:

$$\hat{p}(x) = \frac{1}{n} \sum_{i=1}^{n} \exp\left(-\frac{\|x - x_i\|^2}{2h^2}\right), \tag{2}$$

em que h é a largura da janela, também chamada de *bandwidth*. A ideia implementada foi deslocar cada ponto em direção a regiões de maior densidade, por meio de uma média ponderada pelos pesos do kernel Gaussiano. Pontos que convergem para modos próximos da densidade recebem o mesmo rótulo.

Esse procedimento é semelhante em espírito ao Mean Shift, mas foi implementado explicitamente a partir da estimativa de densidade de Parzen. Além dos gráficos dos agrupamentos, também foi gerado um mapa de contorno da densidade estimada no plano PCA 2D, permitindo observar visualmente os picos de densidade e sua relação com os grupos formados.

3.4 Agrupamento por KNN com vizinhos compartilhados

Na terceira proposta, foi construído um grafo baseado em KNN. Cada amostra é representada por um vértice. Dois vértices são conectados quando satisfazem dois critérios: eles aparecem como vizinhos mútuos e possuem um número mínimo de vizinhos compartilhados. Depois disso, os clusters são definidos como componentes conexas do grafo.

Essa abordagem é inspirada na ideia de que pontos pertencentes ao mesmo grupo não estão apenas próximos, mas também compartilham uma vizinhança local semelhante. Isso evita algumas conexões fracas que poderiam surgir quando se usa apenas a distância direta entre pares de pontos.

4 Avaliação qualitativa

A avaliação foi feita principalmente por visualização. Para cada dataset, o são gerados gráficos em PCA 2D comparando: as classes esperadas; os grupos obtidos por BSAS seguido de K-Means; grupos obtidos por Janelas de Parzen; grupos obtidos pelo método KNN com vizinhos compartilhados.

Também são exibidas métricas de apoio: ARI, NMI e Silhouette. ARI e NMI comparam os agrupamentos com os rótulos conhecidos, enquanto a Silhouette avalia a separação e coesão dos grupos sem usar os rótulos verdadeiros. Como a proposta da atividade enfatiza avaliação qualitativa, essas métricas devem ser lidas apenas como complemento às visualizações.

5 Discussão dos resultados

5.1 Iris Dataset

No Iris Dataset, espera-se que uma das classes seja visualmente mais separável, enquanto as outras duas apresentem sobreposição parcial. Esse comportamento é conhecido no conjunto Iris: a classe Setosa costuma ser bem separada, enquanto Versicolor e Virginica tendem a ocupar regiões mais próximas no espaço de atributos.

Na abordagem BSAS seguido de K-Means, quando o valor estimado de k se aproxima do número esperado de classes, o resultado tende a refletir bem essa estrutura: um grupo mais isolado e dois grupos com fronteira menos evidente. Entretanto, a qualidade do resultado depende da estabilidade do plateau escolhido em $k(\tau)$. Se a curva apresentar vários plateaus plausíveis, a escolha de k pode mudar dependendo da faixa de τ analisada.

No método por Janelas de Parzen, a interpretação visual da densidade é particularmente útil. Picos de densidade bem separados tendem a corresponder a grupos mais claros. No caso do Iris, a sobreposição entre duas classes pode fazer com que a densidade apresente modos próximos ou até mesmo um modo compartilhado, dependendo do *bandwidth*. Assim, o método pode fundir grupos quando a janela é larga demais ou fragmentar grupos quando a janela é muito estreita.

No método KNN com vizinhos compartilhados, a classe mais isolada tende a formar uma componente bem definida. Já as classes parcialmente sobrepostas podem ser ligadas por arestas locais se compartilharem vizinhos suficientes. Portanto, a fronteira entre os dois grupos menos separados é bastante sensível aos parâmetros K e ao número mínimo de vizinhos compartilhados.

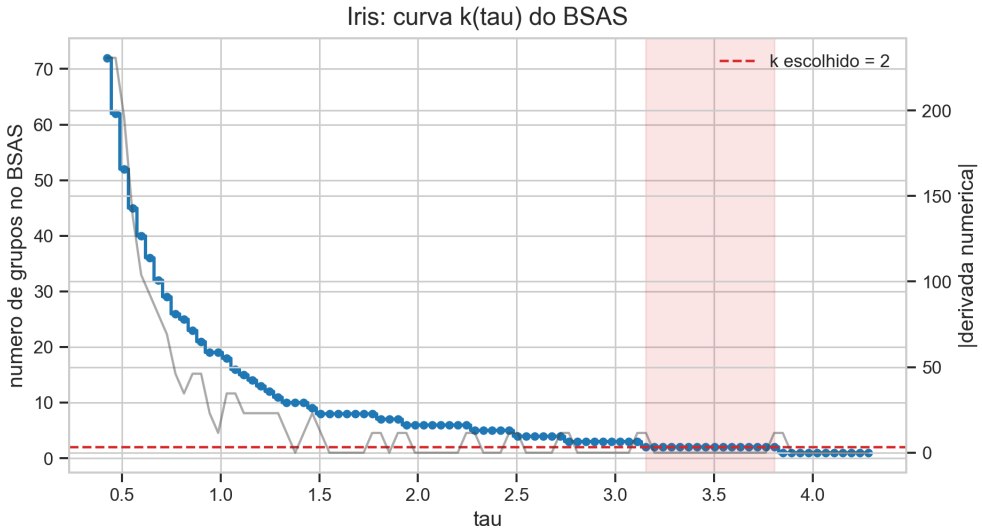

Figura 1: Curva $k(\tau)$ usada para apoiar a escolha do número de grupos no Iris.

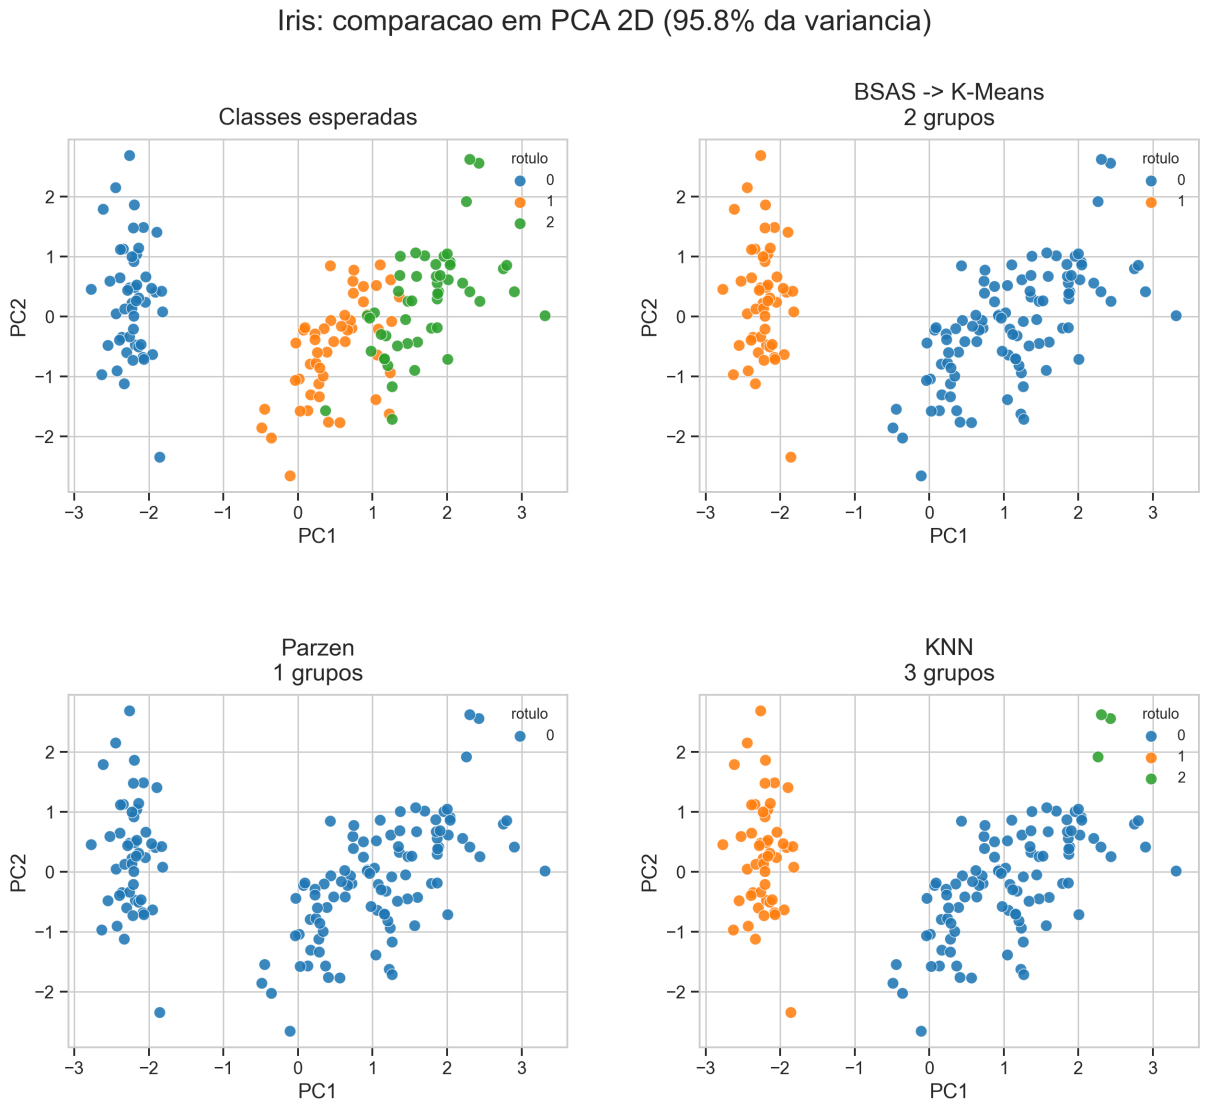

Figura 2: Comparação qualitativa dos agrupamentos do Iris no plano PCA 2D.

5.2 Wine Dataset

No Wine Dataset, a padronização é ainda mais importante, pois os atributos possuem escalas numéricas muito diferentes. Após esse pré-processamento, a PCA geralmente evidencia uma separação razoável entre as classes, embora algumas regiões possam permanecer próximas.

A combinação BSAS e K-Means tende a funcionar bem quando a curva $k(\tau)$ apresenta um plateau associado a um número de grupos compatível com a estrutura esperada. A vantagem dessa abordagem é a interpretabilidade da escolha de k: o gráfico permite visualizar se o número de grupos foi escolhido em uma região estável ou em uma transição abrupta.

No caso do Parzen, a escolha da largura da janela tem impacto direto na resolução da densidade. Como Wine possui mais atributos que Iris, a estimativa de densidade pode ser mais difícil devido ao aumento da dimensionalidade. Em dimensões mais altas, os pontos tendem a ficar mais esparsos, o que torna a escolha do *bandwidth* mais delicada.

O método KNN com vizinhos compartilhados pode capturar estruturas locais interessantes, principalmente quando os grupos possuem densidades diferentes. Por outro lado, se K for pequeno demais, o grafo pode se fragmentar em muitas componentes. Se K for grande demais, regiões distintas podem ser conectadas, reduzindo a separação entre grupos.

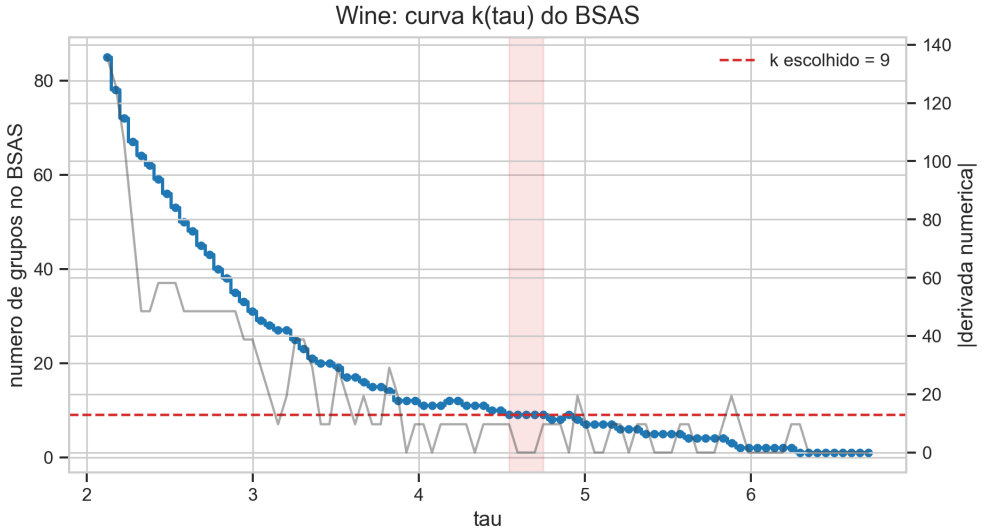

Figura 3: Curva $k(\tau)$ usada para apoiar a escolha do número de grupos no Wine.

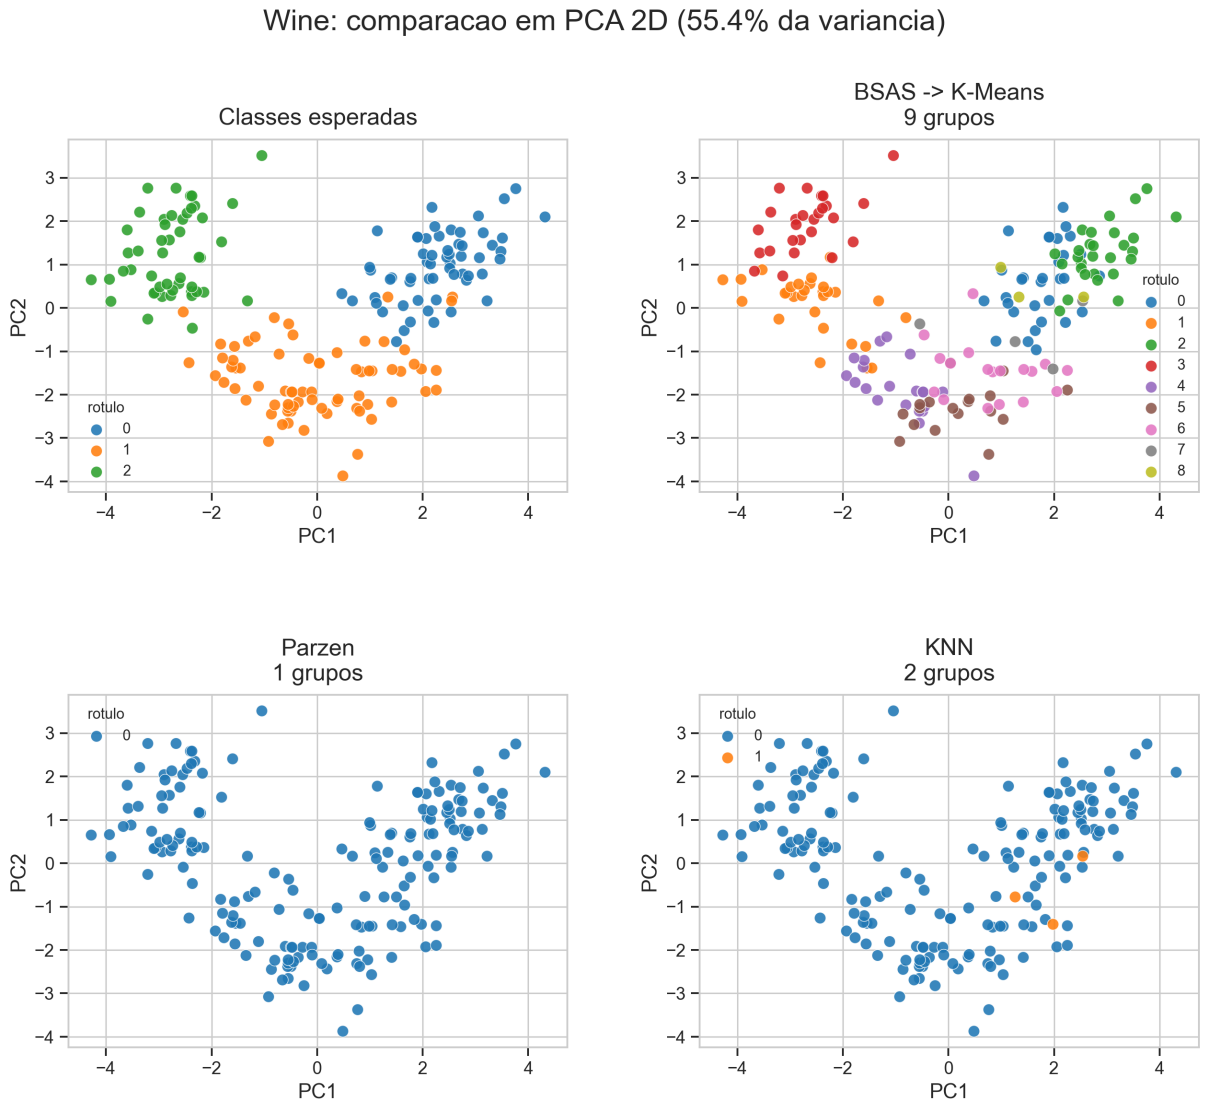

Figura 4: Comparação qualitativa dos agrupamentos do Wine no plano PCA 2D.

6 Sensibilidade a parâmetros

Os três procedimentos possuem parâmetros importantes. A Tabela 1 resume os principais efeitos observados.

Tabela 1: Sensibilidade dos métodos aos principais parâmetros.

Metodo	Parâmetro	Efeito principal
BSAS	τ	Controla a criação de novos grupos.
K-Means	k	Define diretamente o número de clusters finais.
Parzen	h	Controla a suavização da densidade estimada.
KNN	K	Controla o tamanho da vizinhança local.
KNN	vizinhos compartilhados	Controla a rigidez das conexões do grafo.

No BSAS, τ é o parâmetro mais crítico. Valores baixos levam a muitos clusters; valores altos levam a poucos clusters. A estratégia de observar plateaus na curva $k(\tau)$ reduz essa arbitrariedade, mas não elimina completamente a necessidade de julgamento.

No K-Means, o parâmetro k determina o número final de grupos. Por isso, usar o BSAS como etapa anterior é uma forma de tornar a escolha mais fundamentada. Ainda assim, se o BSAS estimar um k inadequado, o K-Means herdará essa limitação.

No Parzen, a largura da janela h controla a suavidade da densidade. Um h muito pequeno gera muitos picos locais e pode fragmentar os dados. Um h muito grande suaviza demais a densidade e pode unir grupos distintos.

No KNN, K e o número mínimo de vizinhos compartilhados controlam a conectividade do grafo. Parâmetros muito permissivos criam conexões entre grupos distintos; parâmetros muito restritivos quebram grupos naturais em várias componentes pequenas.

7 Vantagens e desvantagens

Tabela 2: Comparação qualitativa das abordagens implementadas.

Metodo	Vantagens	Desvantagens
BSAS + K-Means	Estima automaticamente k; possui interpretação visual pela curva $k(\tau)$; K-Means é simples e eficiente.	BSAS é sensível à ordem dos dados; K-Means favorece grupos aproximadamente esféricos; resultado depende do plateau escolhido.
Parzen	Relaciona agrupamentos a regiões de alta densidade; pode encontrar grupos sem impor diretamente um valor de k; densidade estimada é visualizável.	Muito sensível ao *bandwidth*; sofre em dimensionalidade alta; pode fundir ou fragmentar grupos dependendo da suavização.
KNN	Explora estrutura local; pode lidar melhor com formatos não esféricos; evita algumas conexões fracas usando vizinhos compartilhados.	Sensível a K e ao critério de vizinhos compartilhados; pode gerar muitas componentes pequenas; custo de construir vizinhanças cresce com o número de amostras.

8 Limitações

Uma limitação geral é que as visualizações em PCA 2D mostram apenas uma projeção dos dados. Separações ou sobreposições vistas no gráfico podem não representar perfeitamente a geometria no espaço original. Portanto, os gráficos devem ser interpretados como apoio qualitativo, não como prova absoluta da estrutura dos grupos.

Outra limitação é a dependência de parâmetros. Embora tenham sido usadas regras automáticas ou semi-automáticas para definir alguns valores, ainda existe sensibilidade a escolhas como τ, *bandwidth*, K e número mínimo de vizinhos compartilhados. Uma análise mais completa poderia testar grades de parâmetros e avaliar a estabilidade dos agrupamentos.

O BSAS também apresenta dependência da ordem dos dados. A implementação reduz esse problema ao executar múltiplos embaralhamentos e usar a mediana de k, mas isso não remove totalmente a característica sequencial do método.

Por fim, os datasets Iris e Wine são relativamente pequenos e bem conhecidos. Em bases maiores, com ruído, atributos irrelevantes ou estruturas mais complexas, o comportamento dos métodos pode ser diferente. Especialmente no caso de Parzen, a estimativa de densidade pode se tornar mais difícil em dimensões elevadas.

9 Conclusão

A atividade mostrou que diferentes ideias de agrupamento enfatizam aspectos distintos dos dados. A combinação BSAS + K-Means é uma alternativa útil quando se deseja estimar o número de clusters antes de aplicar um particionador clássico. A análise da curva $k(\tau)$ e de sua derivada numérica fornece uma justificativa visual e quantitativa para a escolha de k.

O método baseado em Janelas de Parzen oferece uma interpretação por densidade: grupos são associados a regiões de maior concentração de pontos. Essa abordagem é intuitiva e visualmente rica, mas depende fortemente da largura da janela. O método KNN, por sua vez, modela a estrutura local dos dados por meio de um grafo, sendo interessante para identificar grupos conectados por vizinhanças semelhantes.

Em termos práticos, nenhuma abordagem é universalmente superior. BSAS + K-Means é simples e eficiente, mas assume uma estrutura de grupos mais regular. Parzen é mais flexível em termos de densidade, mas é sensível à suavização. KNN captura relações locais, mas depende da conectividade do grafo. Assim, a melhor interpretação dos resultados surge da combinação entre visualização, métricas de apoio e análise crítica da sensibilidade dos parâmetros.